

Design of an Artificial Intelligence Algorithm based on Neural Networks for Rutinary Movements and Cardiac Arrhythmias Differentiation in ECG Monitoring on Wearables

Rogger Anthony Huamán Gonzales
Facultad de Ciencias e Ingeniería
Universidad Peruana Cayetano Heredia
Lima, Perú
rogger.huaman@upch.pe

Alejandro Javier Rosas
González-Zúñiga
Facultad de Ciencias e Ingeniería
Universidad Peruana Cayetano Heredia
Lima, Perú
alejandro.rosas@upch.pe

Hiroshi Julio Kameya Inafuku
Facultad de Ciencias e Ingeniería
Universidad Peruana Cayetano Heredia
Lima, Perú
hiroshi.kameya@upch.pe

David Sebastián Puma Silva
Facultad de Ciencias e Ingeniería
Universidad Peruana Cayetano Heredia
Lima, Perú
david.puma@upch.pe

Diego Alberto Cuba Monterola
Facultad de Ciencias e Ingeniería
Universidad Peruana Cayetano Heredia
Lima, Perú
diego.cuba@upch.pe

Abstract

This work presents the development of an artificial intelligence model for the precise detection of arrhythmic signals and artifacts caused by scratching near an electrode. Currently, many ECG monitoring devices lack the precision needed to distinguish these events, limiting their effectiveness in clinical practice. To address this challenge, a deep learning model was trained using the Edge Impulse platform, employing processing blocks such as spectrograms and spectral analysis. Different configurations of these blocks were evaluated, and a classification block was used to label the signals and improve the model's accuracy. After training and testing, high accuracy was achieved in signal classification. The model was then implemented on an Arduino Nano 33 BLE Sense board, utilizing the Edge Impulse environment for feature generation and real-time testing. Additionally, a web interface was developed to visualize and analyze the results, which also showed satisfactory outcomes. This approach contributes to the development of more precise and accessible solutions for arrhythmia and artifact detection in ECG monitoring devices, particularly wearables.

Keywords - *Artificial Intelligence, Deep Learning, ECG Monitoring, Arrhythmia Detection, Artifact Detection, Arduino Nano 33 BLE Sense, Signal Classification, Web Interface*

Introducción

Las enfermedades cardiovasculares son la principal causa de muerte a nivel mundial según la OMS [1], el riesgo de padecer este tipo de enfermedades incrementa con la edad y el hábito de la persona. Las arritmias, caracterizadas por un ritmo cardíaco anómalo, que se manifiestan de manera intermitente o continua, y su diagnóstico temprano es crucial para prevenir complicaciones graves, como accidentes cerebrovasculares y paro cardíaco. En respuesta a esta creciente necesidad de monitoreo continuo, han surgido nuevos desarrollos tecnológicos que facilitan la detección y diagnóstico de esta condición. Dentro de los cuales se encuentran los electrocardiogramas (ECG) [2], Holters [3], Ecocardiograma [4], Tomografía Computarizada [5], entre otros.

Los ECG y los dispositivos Holter son herramientas clave para la detección de enfermedades cardiovasculares, ya que registran los impulsos eléctricos generados por el corazón. Estos dispositivos pueden proporcionar información sobre la actividad eléctrica del corazón durante un período determinado, lo que permite a los médicos diagnosticar condiciones como la fibrilación auricular, la taquicardia y la bradicardia. Sin embargo, estos métodos de monitoreo, especialmente los Holters, tienen limitaciones, requieren que los pacientes mantengan un comportamiento controlado durante el monitoreo, evitando movimientos que puedan interferir con la calidad de los datos. Este tipo de interferencias es comúnmente conocido como "artefactos de movimiento" y puede generar falsos positivos,

dificultando la correcta interpretación de las señales cardíacas.

En los últimos años, los dispositivos wearables han emergido como una alternativa para el monitoreo continuo de arritmias cardíacas. Sin embargo, estos dispositivos enfrentan desafíos significativos relacionados con la precisión en la detección de arritmias, debido a su vulnerabilidad a los artefactos causados por movimientos cotidianos. La ineficiencia de los parámetros de monitoreo y la falta de una distinción adecuada entre los movimientos rutinarios y las arritmias reales son factores que contribuyen a los falsos positivos [6].

Planteamiento del problema

A pesar del creciente uso de dispositivos wearables para el monitoreo ambulatorio de arritmias cardíacas mediante electrocardiogramas (ECG), persisten importantes desafíos relacionados con la precisión de los diagnósticos. Uno de los principales problemas radica en la presencia de artefactos, especialmente los artefactos de movimiento (MA), los cuales alteran tanto parcial como completamente los trazados de ECG, complicando su interpretación y, por ende, afectando la fiabilidad del diagnóstico. Estos artefactos pueden originarse por diversas causas, como temblores musculares, tensión, movimientos del paciente o incluso condiciones como fiebre, hipotermia o reanimación cardiopulmonar [7][8].

Los movimientos rutinarios del paciente, tales como el cepillado de dientes, conocido como "toothbrush tachycardia" [9], o el rascado en la zona del pecho, son ejemplos claros de cómo actividades cotidianas pueden generar interferencias significativas en el trazado de ECG. Este fenómeno se ha convertido en un área de interés para la investigación, dado que puede resultar en falsos positivos, llevando a diagnósticos erróneos de arritmias, como taquicardias o fibrilaciones auriculares.

La carencia de softwares especializados en dispositivos wearables que sean capaces de diferenciar entre los artefactos generados por movimientos rutinarios y las patologías reales en las señales bioeléctricas es una de las principales limitaciones en la efectividad del monitoreo cardíaco remoto. Esta deficiencia limita la capacidad de los dispositivos para proporcionar diagnósticos precisos y alertas confiables, lo que podría tener implicaciones

negativas en la salud de los pacientes que dependen de este monitoreo continuo.

Es por ello que la problemática central radica en la falta de precisión en los sistemas de monitoreo de ECG wearables, específicamente en su incapacidad para **distinguir entre artefactos de movimiento rutinarios y las arritmias cardíacas reales**, lo que compromete la fiabilidad de las alertas y diagnósticos generados por estos dispositivos.

Propuesta de solución

En base a la problemática identificada, la propuesta de solución consiste en el desarrollo de un algoritmo de inteligencia artificial basado en redes neuronales, el cual nos permita finalmente poder distinguir y clasificar las señales de ECG que sean auténticas arritmias de las que posean artefactos por actividades rutinarias que simulen el comportamiento de un señal arrítmica. Este algoritmo, al ser basado en redes neuronales, requiere de una gran cantidad de datos para poder ser acondicionado de manera apropiada y tener un buen rendimiento, por lo que contar con un gran volumen de datos es parte esencial de la metodología a seguir. De igual manera, se plantea la exportación del modelo obtenido a otras plataformas con el fin de dotar de mayor versatilidad y capacidad de interacción con el usuario, abriendo así la posibilidad de un mayor desarrollo a futuro. El enfoque descrito anteriormente busca subsanar los desafíos que presentan los wearables en cuanto a identificación, pudiéndose añadir como una etapa final a los algoritmos que ya poseen para una mayor fiabilidad de detección.

A. Bases de datos

Como se mencionó anteriormente, es necesario un gran volumen de datos para entrenar correctamente al modelo. Estos datos tienen que corresponder a señales arrítmicas como señales con artefactos de actividades rutinarias (en este caso rascarse).

Para el primer tipo de datos, se consideró el uso de la base de datos *A large scale 12-lead electrocardiogram database for arrhythmia study* [10]. En esta base de datos, se encuentran las 12 derivaciones de cada uno de los 45 152 pacientes registrados, las cuales presentan ritmos anómalos. Cabe recalcar que la data de esta base de datos fue captada a 500 Hz, y está dividida en segmentos de 10 segundos.

Por otro lado, la necesidad de señales ECG con un artefacto producido por un movimiento tan específico representó una dificultad para encontrar una base de datos que cumpla con esta demanda. En ese sentido, se optó por la elaboración de una base de datos propia de señales ECG que incluyan este artefacto, obtenidas de voluntarios. Esta base de datos fue elaborada de la siguiente manera:

1. Se informó a los voluntarios acerca del objetivo del proyecto, al igual que el procedimiento a seguir.
2. Posicionar al voluntario sentado sobre una silla.
3. Colocar los electrodos en la posiciones correspondientes para obtener las tres derivaciones bipolares: electrodos positivos en brazo izquierdo y pierna izquierda, negativo en brazo derecho y tierra en pierna derecha.
4. Preparar los códigos para la toma y captura de datos.
5. Solicitar al voluntario realizar un leve rascado alrededor del electrodo del brazo izquierdo.
6. Iniciar la toma de datos. Este proceso dura 50 segundos.
7. Terminada la adquisición de datos, solicitar al paciente que deje de realizar el rascado durante 5 minutos para evitar la fatiga e irritación.
8. Repetir los pasos 4-7 tres veces más, y de forma subsecuente para cada voluntario.

Estas señales de ECG fueron captadas gracias a dos módulos AD8232, controlados por un ESP32 WROOM 32E, configurado para una frecuencia de muestreo de 500 Hz. Estos módulos obtenían la data para la primera y segunda derivación, lo cual nos permitía calcular la tercera derivada a medida que adquirimos los datos en tiempo real.

$$DIII = DII - DI$$

La data obtenida para esta base de datos se guardó en formato .CSV, en tres derivadas por archivo.

B. Importación y preprocesamiento de datos

Si bien tenemos el conjunto de señales de la base de datos de ECG con artefactos en .CSV, las señales de la base de datos de arritmias no se encuentran en este formato, sino en .MAT. En vista a eso, se importaron los datos mediante código en Python a formato .CSV, rescatando las tres primeras

derivaciones. Esto nos permite obtener, de manera análoga a la base de datos de artefactos, tres derivadas por archivo.

Posterior a esto, se separaron las tres derivaciones a archivos distintos, por lo que de un archivo de tres derivadas se obtuvieron tres archivos nuevos, con una derivada cada uno. Sumado a esto, y exclusivamente para la base de datos de artefactos, cada señal fue dividida en cinco segmentos, lo que nos dio segmentos de 10 segundos de duración (recordemos que el tiempo total era de 50 segundos). Esto nos permitió obtener un mayor volumen de datos, tanto de señales arritmicas como con artefacto: 282 señales arritmicas y 165 de artefacto.

Cada señal fue sometida a un preprocesamiento mediante dos tipos de filtro.

- *Filtro Butterworth:* Este filtro pasabandas de quinto orden permite separar nuestra señal del ruido de alta frecuencia. Se configuró como frecuencia de corte a 0.5 y 100 Hz ya que las señales de ECG tienen su información dentro de este rango de frecuencias [11].
- *Filtro Notch:* El filtro Notch nos permite eliminar con mayor precisión los componentes pertenecientes a un valor específico de frecuencia. Esto es útil en el contexto del ruido por la red eléctrica, el cual existe en un valor de frecuencia conocido. En ese sentido, se aplicó un filtro Notch con $f_0 = 60$ Hz para las señales con artefacto (red eléctrica peruana) y otro filtro con $f_0 = 50$ Hz para las señales provenientes de la base de datos de PhysioNet (red eléctrica japonesa).




Fig. 1: Respuesta en frecuencia del filtro pasabandas




Fig. 2: Respuesta en frecuencia del filtro Notch (para 60 Hz)

Tras estos procesos, la data queda lista para ser procesada.

C. Edge Impulse

Para facilitar la elaboración del algoritmo, se hizo uso de la herramienta Edge Impulse, una plataforma para la creación de modelos de inteligencia artificial. Se subieron todas las señales a la plataforma, la cual nos permitió categorizarlas en arritmia o artefacto. Esto finalmente hizo que generamos un dataset dentro de la plataforma, el cual será usado para alimentar al modelo. Este dataset tiene una distribución de 80/20 (train/test).

Posteriormente, se procedió a la creación del modelo como tal. Edge Impulse divide las partes de sus modelos en dos categorías principales:

- *Processing blocks*: Los datos pasan primero por este bloque. En esta etapa, los datos del dataset son procesados antes de que sean enviados al *learning block*. Este procesamiento implica la extracción de características, lo cual es fundamental para un aprendizaje eficiente. Edge Impulse permite añadir distintos tipos de bloques de procesamiento, y en este caso se eligieron los bloques *Spectral Analysis* y *Spectrogram*.
- *Learning blocks*: Ajusta al modelo para aprender patrones a partir de las características obtenidas. Esto permite al modelo finalmente generar predicciones, asociando características a su correspondiente categoría. En este caso, se usó el bloque *Classification*.

Los *processing blocks* permiten realizar configuraciones adicionales a cada uno. Para el caso de *Spectral Analysis*, se puede elegir el tipo de análisis a realizar: por wavelet o FFT. Tras distintas pruebas, se halló que se obtuvieron mejores resultados con

análisis el wavelet bior 1.3. Esto concuerda con la literatura, ya que este wavelet es bastante utilizado en lo que respecta a señales ECG. Tras guardar esta configuración, podemos visualizar que tan bien este bloque permite separar las clases.




Fig. 3: Feature explorer de Spectral Analysis

Para Spectrogram, tras distintas pruebas, se eligieron los parámetros:

- Frame length: 0.2
- Frame stride: 0.05
- FFT length: 128

Obteniendo así la siguiente separación de clases.




Fig. 4: Feature explorer de Spectrogram

De igual manera, los *learning blocks* también permiten cierto grado de configuración. Para este caso del modelo propuesto, se configuraron cuatro capas densas (100, 50, 20 y 10 neuronas), al igual que 200 ciclos de entrenamiento y una tasa de aprendizaje de 0.0005. Teniendo configurados los parámetros necesarios para el modelo, se procedió a entrenarlo y luego realizar el testeo.

D. Implementación

a. Streamlit

Para la implementación del modelo se realizó la integración del modelo desarrollado en Edge Impulse en una interfaz de usuario amigable como Streamlit. Para realizar esto, se exportó el modelo en formato Keras y se implementó un código. De este modo, se obtuvo una interfaz donde se ingresa las características de

la señal ECG extraída y se realiza la predicción sobre si corresponde a un movimiento rutinario o arritmia cardíaca. Finalmente, se alojó esta implementación en una dirección web pública.

b. Arduino Nano 33 BLE Sense

De igual manera, se optó por implementar el modelo en esta placa de la familia Arduino. Este modelo en particular está preparado para alojar modelos de Machine Learning. El propósito de la implementación en esta placa es porque abre la posibilidad de un mayor desarrollo debido a una serie de características que la placa otorga al sistema en conjunto. Por ejemplo, inferencias de forma local, operación autónoma, y la posibilidad de conectar otros sensores a la placa con el fin de mejorar funcionalidades. Esta exportación a la placa Arduino se logró descargando el modelo en forma de librería en la sección de *Deployment*.

Resultados

Tras el entrenamiento, testeo e implementación en distintas plataformas, se obtuvieron los siguientes resultados. En Edge Impulse, tras el entrenamiento se obtuvieron las siguientes métricas y matriz de confusión.



Fig. 5: Métricas del grupo de entrenamiento



Fig. 6: Resultados de la clasificación en el grupo de entrenamiento

Destaca un accuracy de 92.9%, lo que nos da un buen indicio del rendimiento del modelo. De igual manera, resalta la capacidad de distinguir correctamente los verdaderos positivos y verdaderos negativos: 98.7% y 86.9% respectivamente. Posteriormente, se realizó el testeo con los datos reservados para esta parte.




Fig. 7: Métricas del grupo de testeo

Podemos apreciar que obtenemos un accuracy aún más alto que en el caso de entrenamiento, lo que nos dice que al momento de evaluar estos datos reservados (y con los que no fue entrenado), puede clasificar correctamente la naturaleza de estas señales: arritmia o artefacto. Nótese que hay un incremento sustancial en el rendimiento de detección de verdaderos negativos (99.7%) respecto al entrenamiento (86.9%).

Tras la implementación en la placa Arduino y Streamlit, se evaluó si el rendimiento visto en Edge Impulse se mantuvo en estas plataformas. Para lograr esto, se le suministró a cada modelo exportado las características (*Raw features*) que extrae Edge Impulse de las señales. El rendimiento aparente no se vio afectado, ya que en ambas implementaciones el modelo pudo seguir prediciendo correctamente el tipo de señal en base a las características que se le suministraban.



Fig. 8: Implementación en Arduino IDE

```

Timing: DSP 20 ms, inference 11 ms, anomaly 0 ms
Predictions:
  arritmia: 0.99609
  rascada : 0.00000
Edge Impulse standalone inferencing (Arduino)
run_classifier returned: 0

```

Fig. 9: Predicción correcta de tipo de señal en monitor serial (arritmia)



Fig. 10: Implementación en Streamlit

Resultados de la predicción (probabilidades):

0	1
0	1

Clase predicha para RascadaA.txt: Artefacto (Rascado)

Resumen de predicciones:

- RascadaA.txt: Artefacto (Rascado)

Fig. 11: Predicción correcta de tipo de señal en Streamlit (artefacto)

Conclusiones:

- Se ha logrado desarrollar satisfactoriamente un algoritmo basado en deep learning para discernir una arritmia cardíaca de un artefacto de movimiento, específicamente referente al rascado, lo que se evidencia en las métricas, como una precisión superior al 90%.
- La implementación del algoritmo en el microcontrolador Arduino Nano 33 BLE Sense y en la página web son factibles y se obtuvieron buenos resultados.
- Debido a que se ha alcanzado la integración satisfactoria del algoritmo en un microcontrolador es que se puede evidenciar la compatibilidad en sistemas embebidos compactos y accesibles, permitiendo la escalabilidad, así como la integración de sistemas inalámbricos o monitoreo remoto.

References

- [1] “Enfermedad pulmonar obstructiva crónica (EPOC)”. Disponible en: [https://www.who.int/es/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/es/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds)).
- [2] Biblioteca Nacional de Medicina de EE. UU., "Electrocardiograma," MedlinePlus, [en línea]. Disponible en: <https://medlineplus.gov/spanish/pruebas-de-laboratorio/electrocardiograma/>.
- [3] Biblioteca Nacional de Medicina de EE. UU., "Monitor Holter (24 horas)," MedlinePlus, [en línea]. Disponible en: <https://medlineplus.gov/spanish/ency/article/003877.htm>.
- [4] Mayo Clinic, "Ecocardiograma," [en línea]. Disponible en: <https://www.mayoclinic.org/es/tests-procedures/echocardiogram/about/pac-20393856>.
- [5] Biblioteca Nacional de Medicina de EE. UU., "Tomografía computarizada," MedlinePlus, [en línea]. Disponible en: <https://medlineplus.gov/spanish/ctscans.html>.
- [6] K.-V. Tran et al., "False Atrial Fibrillation Alerts from Smartwatches are Associated with Decreased Perceived Physical Well-being and Confidence in Chronic Symptoms Management," Cardiology and Cardiovascular Medicine, vol. 7, no. 2, p. 97, 2023. [Online]. Disponible en: <https://www.fortunejournals.com/articles/false-atrial-fibrillation-alerts-from-smartwatches-are-associated.pdf>.
- [7] C. R. Seisdedos, “Análisis del ECG en monitorización ambulatoria para el diagnóstico cardíaco y la predicción de muerte cardíaca súbita”, nov. 2008.
- [8] E. Burns, R. Buttner, y E. B. and R. Buttner, “ECG Motion Artefacts”, Life in the Fast Lane • LITFL, el 1 de agosto de 2018. Disponible en: <https://litfl.com/ecg-motion-artefacts-ecg-library/>.

[9]M. Khalili, H. GholamHosseini, A. Lowe, et al., "Motion artifacts in capacitive ECG monitoring systems: a review of existing models and reduction techniques," Med. Biol. Eng. Comput., 2024. [En línea]. Disponible en: <https://doi.org/10.1007/s11517-024-03165-1>.

[10] J. Zheng, H. Guo, and H. Chu, "A large scale 12-lead electrocardiogram database for arrhythmia study," PhysioNet, version 1.0.0, 2022. [Online]. Available: <https://doi.org/10.13026/wgex-er52>.

[11] J. Bronzino, Medical Devices and Systems. Boca Raton, FL, USA: CRC Press, 2006.

Authors' biography

Rogger Anthony Huamán Gonzales

Rogger Anthony Huamán Gonzales is a 7th-term student at the Pontificia Universidad Católica del Perú and the Universidad Peruana Cayetano Heredia, with an interest in biosignals and research on medical imaging acquisition techniques.

Alejandro Javier Rosas González-Zúñiga

Alejandro Javier Rosas González-Zúñiga is an 8th-term student of Biomedical Engineering at Pontificia Universidad Católica del Perú and Universidad Peruana Cayetano Heredia. He has strong interest in electronics and its application in the development of medical devices, as well as in biosignal processing and project design.

Hiroshi Julio Kameya Inafuku

Hiroshi Julio Kameya Inafuku is a 7th-term student of Biomedical Engineering at Pontificia Universidad Católica del Perú (PUCP) and Universidad Peruana Cayetano Heredia. He has strong interest in areas such as tissue engineering and biomaterial development, as well as the application of artificial intelligence to solve biomedical challenges.

David Sebastián Puma Silva

David Sebastián Puma Silva is an 7th-term student of Biomedical Engineering at Pontificia Universidad Católica del Perú and Universidad Peruana Cayetano Heredia, with an interest in biomechanics and the development of medical devices.

Diego Alberto Cuba Monterola

Diego Alberto Cuba Monterola is an 7th-term student of Biomedical Engineering at Pontificia Universidad Católica del Perú and Universidad Peruana Cayetano Heredia, with an interest in biomedical signals and imaging biomechanics and the development of medical devices.